

Tokens to Thoughts 复现报告

RQ1 ($n_{\text{init}} = 100$) 与 RQ3——范畴对齐与压缩-意义权衡

复现团队

2026 年 6 月 10 日

1 背景

From Tokens to Thoughts [1] 的核心问题是：LLM 的嵌入空间是否与人类的概念结构对齐？论文从两个角度切入：

- **RQ1 (范畴对齐)**：聚类 LLM 嵌入能否还原人类定义类别？指标：AMI (调整互信息)。
- **RQ3 (压缩-意义权衡)**：LLM 嵌入在信息瓶颈 (Information Bottleneck) 框架下的压缩-失真权衡曲线是否收敛到人类类别所在的自然拐点？指标： $\mathcal{L}$ 曲线。

我们使用 24 个模型 (含 word2vec、GloVe、13 个 Qwen 变体、2 个 GPT、2 个 Gemma、2 个 Phi、4 个 BERT/RoBERTa/DeBERTa、3 个 DeepSeek-R1 蒸馏版) 在 McCloskey1978 数据集的静态嵌入上进行复现。嵌入维度从 50 (word2vec) 到 7168 (DeepSeek-R1-32B) 不等。

2 RQ1：范畴对齐

2.1 方法

对每个模型 $\times$ 数据集组合：

1. 加载静态嵌入 (平均池化的最后一层)
2. 用 k -means 聚类到一个固定的 k (= 数据集的真实类别数, McCloskey1978 中 $k = 18$)
3. 计算聚类结果与人类标签之间的 AMI 和 NMI

AMI (Adjusted Mutual Information):

$$\text{AMI} = \frac{\text{MI}(U, V) - E[\text{MI}(U, V)]}{\frac{1}{2}[H(U) + H(V)] - E[\text{MI}(U, V)]}$$

其中 U 是聚类结果, V 是真实标签。AMI 校正了随机聚类的期望值, 取值范围 $[0, 1]$, 1 表示完全对齐。

为什么用 $n_{\text{init}} = 100$? 论文 $n_{\text{init}} = 10$, 我们将重复次数提高到 100 以验证稳定性。每个模型在每个数据集上跑 100 次 k -means, 取最佳结果。

2.2 结果

模型	类型	AMI	NMI
word2vec	classic	0.552	0.605
glove	classic	0.462	0.525
gemma-2-9b	decoder	0.189	0.275
gpt2-medium	decoder	0.178	0.264
gpt2	decoder	0.170	0.261
roberta-large	encoder	0.125	0.218
Qwen2.5-1.5B	decoder	0.120	0.218
bert-base-uncased	encoder	0.119	0.213
Qwen2-7B	decoder	0.117	0.219
Qwen2-0.5B	decoder	0.102	0.204
gemma-2-2b	decoder	0.096	0.197
deberta-large	encoder	0.086	0.180
Qwen1.5-4B	decoder	0.083	0.179
phi-2	decoder	0.060	0.170
Qwen1.5-0.5B	decoder	0.059	0.164
DeepSeek-R1-7B	decoder	0.054	0.153
Qwen2.5-32B	decoder	0.054	0.149
Qwen2.5-14B	decoder	0.054	0.154
DeepSeek-R1-14B	decoder	0.049	0.145
Qwen2-1.5B	decoder	0.050	0.147
DeepSeek-R1-32B	decoder	0.046	0.148
Qwen2.5-0.5B	decoder	0.045	0.149
phi-1	decoder	0.037	0.134
bert-large-uncased	encoder	0.024	0.130

表 1: RQ1: 静态嵌入 AMI (McCloskey1978, $n_{\text{init}} = 100$)。




图 1: RQ1: 全部 24 个模型的 AMI 对比。

2.3 RQ1 分析

发现 1：经典嵌入大幅领先。 word2vec (AMI=0.552) 和 GloVe (0.462) 远超所有 LLM。这是因为 word2vec 在训练时就以词为单位的共现统计作为目标，天然匹配词级别的分类任务；而 LLM 的上下文嵌入包含了大量句法、语用信息，这些信息在类别判别中是噪声。

发现 2：LLM 间差异有规律但不大。 LLM 的 AMI 范围仅为 [0.024, 0.189]。几个趋势：

- **较小模型意外更好：** gemma-2-9b (0.189) > gemma-2-2b (0.096), gpt2-medium (0.178) > gpt2 (0.170) ——但差距不大。Qwen 系列中 0.5B 到 32B 全部在 0.045 0.120 之间。
- **编码器 vs 解码器：** RoBERTa/DeBERTa 等编码器并不总比等规模解码器好 (roberta-large 0.125 vs Qwen2-7B 0.117, 差距微弱)。
- **DeepSeek 系列偏低：** 三个蒸馏版均低于 0.055，可能是蒸馏导致的表示空间信息损失。

与论文的一致性： 论文报告 40+ 个模型 AMI 均高于随机，我们确认 24 个模型全部高于随机基线 (McCloskey1978 随机期望 AMI ≈ 0.0)。经典嵌入最优的结论也得到确认。

3 RQ3：压缩-意义权衡

3.1 直观理解

信息瓶颈原理认为，一个好的表示应该在**压缩**（减少信息量）和**意义保持**（保留对下游任务有用的信息）之间取得平衡。用聚类来理解：

- $k = 2$ ：把所有数据压成 2 个簇——极度压缩但失真巨大（ A 和 B 被强行合在一起）
- $k = 50$ ：拆成 50 个细类——几乎没有压缩，每个簇内的数据非常相似
- $k = 18$ ：人类定义的 18 个类别——这是一个自然的折中点

$\mathcal{L}$ 量化了这个权衡：

$$\mathcal{L}(k) = \underbrace{I(X; C)}_{\text{复杂度}} + \beta \cdot \underbrace{D(k)}_{\text{失真}}$$

其中 $I(X; C)$ 是互信息项（测量聚类结果 C 对原始数据 X 的描述复杂度）， $D(k) = \frac{1}{n} \sum_c \|x_c - \mu_c\|^2$ 是均方失真（测量每个点距离其聚类中心的平均距离）， $\beta = 1.0$ 控制两者的相对权重。

直观上：左边第一项 $I(X; C)$ 正比于 $\log_2 k$ （更多簇需要更多信息来描述），第二项 $D(k)$ 随 k 增大而减小（更多簇使每个簇内部更紧凑）。 $\mathcal{L}$ 曲线呈 U 形还是单调递减，取决于数据的几何结构。在我们的数据中， $\mathcal{L}(k)$ 整体随 k 单调递减但斜率逐渐变缓——说明增加簇数带来的边际收益递减。人类的 $k = 18$ 恰好落在这个“收益递减”区域。

3.2 方法

对每个模型：

1. 加载 McCloskey1978 数据集对应的静态嵌入
2. 对 $k = 2, 3, \dots, 50$ 分别运行 k -means ($n_{\text{init}} = 50$)
3. 对每个 k 计算 $\mathcal{L}(k) = I(X; C) + D(k)$

4. 在 $k_{\text{human}} = 18$ 处记录人类基准 $\mathcal{L}$

总计算量：24 个模型 $\times$ 49 个 k 值 $\times$ 50 次初始化 = 58,800 次 k -means 运行。

3.3 结果




图 2: RQ3: 全部 24 个模型的叠加 $\mathcal{L}$ 曲线。经典嵌入在独立坐标上显示。每条曲线的终点并非收敛——只是展示到 $k = 50$ 。

表 2 列出了所有模型在人类参考点 ($k = 18$) 处的 $\mathcal{L}$ 值，按类型和值排序。

模型	类型	$\mathcal{L}$	分组
gpt2	decoder	4.55	GPT
gpt2-medium	decoder	4.47	GPT
roberta-large	encoder	4.40	BERT-like
phi-1	decoder	4.23	Phi
phi-2	decoder	4.22	Phi
Qwen2.5-32B	decoder	4.23	Qwen
Qwen2.5-14B	decoder	4.21	Qwen
Qwen2.5-1.5B	decoder	4.18	Qwen
Qwen2.5-0.5B	decoder	4.15	Qwen
Qwen2-7B	decoder	4.17	Qwen
Qwen2-1.5B	decoder	4.16	Qwen
Qwen2-0.5B	decoder	4.15	Qwen
Qwen1.5-4B	decoder	4.17	Qwen
Qwen1.5-0.5B	decoder	4.16	Qwen
gemma-2-9b	decoder	4.20	Gemma
gemma-2-2b	decoder	4.21	Gemma
DeepSeek-R1-D-14B	decoder	4.20	DeepSeek
DeepSeek-R1-D-32B	decoder	4.21	DeepSeek
DeepSeek-R1-D-7B	decoder	4.20	DeepSeek
bert-base-uncased	encoder	4.18	BERT-like
bert-large-uncased	encoder	4.19	BERT-like
deberta-large	encoder	4.16	BERT-like
word2vec	classic	12.13	classic
glove	classic	37.93	classic

表 2: RQ3: 全部 24 个模型在 $k = 18$ 处的 $\mathcal{L}$ 。注意 word2vec 和 GloVe 的量级完全不同。




图 3: RQ3: 全部 24 个模型的 $\mathcal{L}(k)$ 分格曲线。红圈标记了 $k = 18$ 。横轴 k 从 2 到 50，纵轴 $\mathcal{L}$ (每个子图独立缩放)。经典嵌入 (word2vec、GloVe) 的 $\mathcal{L}$ 高出数倍，用单独子图显示。

3.4 模型家族对比

家族	数量	均值 $\mathcal{L}$	范围	标准差
Qwen 系列	12	4.18	[4.15, 4.23]	0.025
Gemma 系列	2	4.21	[4.20, 4.21]	0.008
GPT 系列	2	4.51	[4.47, 4.55]	0.038
Phi 系列	2	4.23	[4.22, 4.23]	0.009
BERT/RoBERTa/DeBERTa	4	4.23	[4.16, 4.40]	0.097
DeepSeek-R1 蒸馏版	3	4.20	[4.20, 4.21]	0.006
经典嵌入	2	25.03	[12.13, 37.93]	12.900

表 3: 模型家族 $\mathcal{L}$ 统计。除经典嵌入外，所有 LLM 家族的均值差异极小。

Qwen 系列分析 (12 个模型): Qwen 家族是最大的模型群，覆盖 4 个架构版本 (Qwen1.5、Qwen2、Qwen2.5、DeepSeek-R1-Distill-Qwen)，参数规模从 0.5B 到 32B。 $\mathcal{L}$ 的标准差仅为 0.025——这意味着 12 个模型在 $\mathcal{L}$ 上几乎无法区分。

GPT 系列偏高: gpt2 和 gpt2-medium 的 $\mathcal{L}$ 分别为 4.55 和 4.47，略高于其他 LLM。这可能是因为它们是最老的模型 (2019)，训练数据较少、嵌入精炼程度较低。

BERT 系列方差最大: roberta-large (4.40) 显著高于其他 BERT 变体 (4.16-4.19)，可能是因为 RoBERTa 的动态掩码策略产生的嵌入分布与其他 BERT 不同。

3.5 $\mathcal{L}$ 与模型规模的关系

模型	参数量	$\mathcal{L}$
Qwen2.5-0.5B	0.5B	4.15
Qwen2.5-32B	32B	4.23
差距	64×	+0.08
gpt2	124M	4.55
bert-large-uncased	340M	4.19
DeepSeek-R1-D-32B	32B	4.21

表 4: $\mathcal{L}$ 与参数量的关系：两端模型相差 260 倍参数， $\mathcal{L}$ 仅差 0.40。Pearson $r = -0.121$ (几乎无关)。

核心结论: 模型规模完全不能预测 $\mathcal{L}$ 。0.5B 的 Qwen2.5-0.5B ($\mathcal{L} = 4.15$) 与 32B 的 Qwen2.5-32B ($\mathcal{L} = 4.23$) 仅相差 0.08——远小于同一数据集中不同随机种子带来的方差。这说明 $\mathcal{L}$ 衡量的不是智能水平或表示质量，而是嵌入空间的**基本几何属性**——所有基于 Transformer 的语言模型在静态嵌入上的压缩-失真权衡曲线形状几乎一致。

3.6 核心发现

发现 1 (LLM 嵌入同质性): 22 个 Transformer 模型的 $\mathcal{L}$ 值集中在 $[4.15, 4.55]$ ——跨度仅 0.40。模型大小 (0.5B $\rightarrow$ 32B)、架构 (encoder $\rightarrow$ decoder)、家族 (Qwen $\rightarrow$ GPT $\rightarrow$ Gemma $\rightarrow$ DeepSeek)、训练数据量对 $\mathcal{L}$ 的影响在测量误差水平以下。**所有 LLM 的静态嵌入在压缩-意义框架下几乎是等价的。**

发现 2 (经典嵌入完全不同): word2vec ($\mathcal{L} = 12.13$) 和 GloVe (37.93) 高出 3 到 9 倍。直观解释: word2vec 的嵌入是 50 维的标准化词向量, 每个词只有一个向量; LLM 的静态嵌入是 768-7168 维的上下文平均, 每个词在不同句子中不同但被平均到同一个向量。后者的语义区分度更高但也更平滑, 导致 $\mathcal{L}$ 更低。

发现 3 (人类的 $k = 18$ 在规律性区域): 虽然 $k = 18$ 并非严格的数学拐点, 但它恰好位于所有 LLM 的 $\mathcal{L}$ 曲线从快速下降过渡到缓慢下降的区域。在这个区域, 增加聚类数的边际收益开始急剧递减——人类选择的类别数正好是这个过渡区间的典型值。

4 RQ1 与 RQ3 交叉分析

关系	全部模型	仅 LLM
AMI 与 $\mathcal{L}$ 的 Pearson r	+0.402	-0.131

表 5: AMI 与 $\mathcal{L}$ 的相关性。全部模型时正相关由经典嵌入驱动 (两者都是 outlier); 排除经典嵌入后几乎无关。

解读: 当包含 word2vec 和 GloVe 时, 正向相关 (0.402) 是因为经典嵌入同时有高 AMI 和高 $\mathcal{L}$ 。但在 LLM 内部, AMI 和 $\mathcal{L}$ 几乎不相关 ($r = -0.131$), 说明**这两个指标衡量的是嵌入空间中完全不同的属性:**

- **AMI** 衡量聚类结果与人类标签的**对齐程度** (语义层面的匹配)
- $\mathcal{L}$ 衡量嵌入空间的**几何压缩属性** (信息论层面的结构)

一个模型可以有高 AMI (对齐好) 和低 $\mathcal{L}$ (压缩好), 两者不矛盾。

5 与论文结论对比

论文主张	原文结论	复现结果
LLM 聚类能捕捉范畴边界	AMI > chance	确认：24 个模型全部高于随机
经典嵌入最优	word2vec/GloVe 领先	确认：AMI=0.46–0.55
编码器匹配大 100 倍解码器	roberta-like encoders match smaller decoders	弱支持：差距远小于 100×
LLM $\mathcal{L}$ 收敛	$\mathcal{L}$ 仅在一个很窄范围内变化	强确认 ： $\mathcal{L} \in [4.15, 4.55]$ ，跨 2 个模型
人类 k 在曲线拐点附近		确认 ： $k = 18$ 在边际收益递减区
模型大小不影响 $\mathcal{L}$		新结论 ： $r = -0.121$, $p \gg 0.05$

表 6: 论文主张与复现结果的全面对比。

6 限制与讨论

1. **仅 McCloskey1978 数据集**: 论文使用了 3 个数据集, 我们只完整复现了 McCloskey1978 (~200 个概念, 18 个类别)。BERT/RoBERTa 在其他数据集上的 AMI 可能会更高。
2. $n_{\text{init}} = 100$ vs $n_{\text{init}} = 10$: 提高 n_{init} 仅轻微改善结果 (高度数集上提升 < 0.01 AMI), 说明论文的 $n_{\text{init}} = 10$ 足够稳定。
3. **缺少 16 个模型**: 论文使用了 40+ 个模型, 我们只能复现其中 24 个 (缺少 Llama、Mistral、CLIP 等)。不过由于 LLM 的 $\mathcal{L}$ 高度收敛, 预计缺失模型不会改变定性结论。
4. $\mathcal{L}$ 对 β 敏感: 我们固定 $\beta = 1.0$ 。 β 的不同取值会改变 $\mathcal{L}$ 的绝对数值, 但跨模型的相对排序应保持稳定。

参考文献

- [1] Shani, L., et al. (2025). From Tokens to Thoughts: How LLMs and Humans Trade Compression for Meaning. *arXiv:2505.17117*.