

Tokens to Thoughts 复现报告

信息论视角下的范畴对齐、典型性与压缩-意义权衡

(RQ1——AMI 聚类对齐 / RQ2——典型性 Spearman ρ / RQ3——压缩-意义 $\mathcal{L}$ 曲线)

复现团队

2026 年 6 月 10 日

1 背景

From Tokens to Thoughts [1] 的核心问题是：**LLM 的嵌入空间是否与人类的概念结构对齐**？论文从两个角度切入：

- **RQ1 (范畴对齐)**：聚类 LLM 嵌入能否还原人类定义的类别？指标：AMI (调整互信息)。
- **RQ2 (典型性结构)**：LLM 嵌入中的概念相似度能否预测人类对类别成员的典型性评分？指标：Spearman ρ 。
- **RQ3 (压缩-意义权衡)**：LLM 嵌入在信息瓶颈 (Information Bottleneck) 框架下的压缩-失真权衡曲线是否收敛到人类类别所在的自然拐点？指标： $\mathcal{L}$ 曲线。

我们使用 24 个模型 (含 word2vec、GloVe、13 个 Qwen 变体、2 个 GPT、2 个 Gemma、2 个 Phi、4 个 BERT/RoBERTa/DeBERTa、3 个 DeepSeek-R1 蒸馏版) 在 McCloskey1978 数据集的静态嵌入上进行复现。嵌入维度从 50 (word2vec) 到 7168 (DeepSeek-R1-32B) 不等。

2 信息论基础

本节从信息论第一原理出发，逐步推导本报告使用的全部信息论度量，为后续的实验分析提供严格的数学基础。

2.1 熵 (Entropy)

自信息是信息论最基本的量。对于一个离散随机变量 $X \sim p(x)$ ，事件 $X = x$ 的自信息定义为：

$$I(x) = \log_2 \frac{1}{p(x)} = -\log_2 p(x)$$

单位为比特。自信息刻画了观察到该事件所获得的“惊讶度”——发生概率越低的事件，自信息越大。

熵 (Shannon entropy) 是自信息的期望值，描述了随机变量 X 的平均不确定性：

$$H(X) = \mathbb{E}_X [-\log_2 p(X)] = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x) \quad (1)$$

其中约定 $0 \log_2 0 = 0$ 。熵具有以下基本性质：

- **非负性**： $H(X) \geq 0$ ，当且仅当 X 为确定性变量时取等。

- **上界：** $H(X) \leq \log_2 |\mathcal{X}|$ ，在均匀分布时取等（最大熵原理）。
- **凸性：** $H(X)$ 是 $p(x)$ 的凹函数。

联合熵描述一对随机变量 $(X, Y) \sim p(x, y)$ 的总不确定性：

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 p(x, y) \quad (2)$$

条件熵是在已知 Y 的条件下 X 剩余的不确定性：

$$H(X | Y) = \mathbb{E}_Y [H(X | Y = y)] = - \sum_y p(y) \sum_x p(x | y) \log_2 p(x | y) \quad (3)$$

三者通过**链式法则**相联系：

$$H(X, Y) = H(X) + H(Y | X) = H(Y) + H(X | Y) \quad (4)$$

2.2 互信息 (Mutual Information)

互信息衡量两个随机变量 X 和 Y 之间相互包含的信息量——即知道 Y 能减少 X 的不确定性的程度：

$$I(X; Y) = H(X) - H(X | Y) \quad (5)$$

由链式法则（式 4）可得等价形式：

$$I(X; Y) = H(X) + H(Y) - H(X, Y) \quad (6)$$

互信息也可以直接从联合分布和边缘分布写为 **KL 散度**形式：

$$I(X; Y) = \sum_{x, y} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)} = D_{\text{KL}}(p(x, y) \| p(x)p(y)) \quad (7)$$

这个形式揭示了互信息的本质： $I(X; Y)$ 衡量联合分布 $p(x, y)$ 与独立假设 $p(x)p(y)$ 之间的 **KL 散度**。当 X 和 Y 独立时， $I(X; Y) = 0$ ；当 X 完全决定 Y 时（或反之），互信息达到最大。
互信息的性质：

- **对称性：** $I(X; Y) = I(Y; X)$
- **非负性：** $I(X; Y) \geq 0$ ，当且仅当 X 与 Y 独立时取等
- **上界：** $I(X; Y) \leq \min\{H(X), H(Y)\}$

2.3 数据处理不等式

数据处理不等式 (Data Processing Inequality, DPI) 是信息论中最重要的定理之一，它约束了信息在级联处理中的流向：

定理 1 (Data Processing Inequality). 若 $X \rightarrow Y \rightarrow Z$ 构成马尔可夫链（即 $p(x, z | y) = p(x | y)p(z | y)$ ），则

$$I(X; Y) \geq I(X; Z) \quad (8)$$

换言之，任何对数据的后处理都不能增加它包含的原始信息。

本报告的实验涉及以下马尔可夫链：

原始文本 $\rightarrow$ LLM 嵌入 $\rightarrow k$ -means 聚类 $\rightarrow$ 类别标签

DPI 保证了 $I(\text{原始文本}; \text{类别标签}) \geq I(\text{嵌入}; \text{类别标签}) \geq I(\text{聚类}; \text{类别标签})$ ——聚类的过程只会丢失信息而不会增加信息。这正是 RQ3 的核心：在压缩（通过 k -means 减少信息量）和保留意义（保留对分类有用的信息）之间取得平衡。

2.4 信息瓶颈原理

信息瓶颈 (Information Bottleneck, IB) [2] 是一个统一的信息论框架，用于寻找一个随机变量 T （称为**瓶颈变量**或表示），使得 T 在尽可能压缩输入 X 的同时，保留对目标 Y 的预测能力：

$$\min_{p(t|x)} \mathcal{L}_{\text{IB}} = I(X; T) - \beta I(T; Y) \quad (9)$$

其中：

- $I(X; T)$ 是**压缩项** (rate)，衡量 T 保留了 X 中的多少信息
- $I(T; Y)$ 是**意义项** (distortion/ relevance)，衡量 T 对预测 Y 的有用程度
- $\beta \geq 0$ 是**拉格朗日乘子**，控制压缩与意义的相对权重

当 $\beta \rightarrow 0$ 时，最优解退化为将所有 x 映射到同一个 t （最大压缩、零意义）；当 $\beta \rightarrow \infty$ 时，最优解退化为恒等映射（无压缩、保全部信息）。IB 框架的关键洞察是：**对于给定的数据分布，存在一条由 β 参数化的最优压缩-意义曲线**——称为 **IB 曲线** (rate-distortion 曲线)，每个 β 对应曲线上一个 Pareto 最优的点。

IB 框架与 k -means 聚类的联系见于 [3]：当 T 是离散的类别变量（即聚类结果）、且失真度量采用均方误差时，IB 目标退化为经典 k -means 的正则化形式。这为我们使用 k -means 近似求解 IB 问题提供了理论依据。

3 RQ1：范畴对齐

3.1 方法

目标：检验 LLM 嵌入空间的聚类结构是否与人类定义的概念类别一致。

输入： 每个概念的**静态嵌入** $\mathbf{e}_i \in \mathbb{R}^d$ (d 为嵌入维度，取决于模型)，通过对模型最后一层所有子词 token 做平均池化得到。共 $n \approx 200$ 个概念 (McCloskey1978)，分属 $k_{\text{human}} = 18$ 个人类定义的类别（如”鸟””水果””交通工具”等）。

流程：

1. **加载嵌入**: 从 ‘models_embeddings/model.npy’ (n, d) **k-means 聚类**: *scikit-learn* *KMeans* $n_{\text{init}} = 100$ 次随机初始化, 取最优解) 将所有 n 个点聚成 $k = k_{\text{human}} = 18$ 个簇。k-means 的目标是最小化簇内平方和 (惯性):

$$\min_{\{\mu_1, \dots, \mu_k\}} \sum_{i=1}^n \min_c \|\mathbf{e}_i - \mu_c\|^2$$

其中 μ_c 是簇 c 的质心坐标。 $n_{\text{init}} = 100$ 意味着每次聚类独立运行 100 次随机初始化, 选取惯性最小的结果, 以降低 KMeans 陷入局部最优的风险。

3. **评估对齐**: 将聚类得到的簇标签 $\hat{y}_i$ 与人类真实类别标签 y_i 对比, 计算 AMI 和 NMI。

输出: 每个模型 $\times$ 数据集组合得到一个标量 $\text{AMI} \in [0, 1]$, 1 表示聚类结果与人类标签完全一致, 0 表示与随机分类无异。

3.2 AMI 的严格推导

互信息 MI 衡量聚类结果 U 与真实标签 V 之间的关联。给定 n 个样本, 设 U 有 r 个簇, V 有 c 个类别, 定义**列联表** (contingency table): n_{ij} 为同时属于 U 的簇 i 和 V 的类别 j 的样本数; $a_i = \sum_j n_{ij}$ 为簇 i 的总数, $b_j = \sum_i n_{ij}$ 为类别 j 的总数。

由此构造经验概率分布:

$$p(i, j) = \frac{n_{ij}}{n}, \quad p_U(i) = \frac{a_i}{n}, \quad p_V(j) = \frac{b_j}{n}$$

代入互信息的定义 (式 6):

$$\text{MI}(U, V) = \sum_{i=1}^r \sum_{j=1}^c \frac{n_{ij}}{n} \log_2 \frac{n_{ij}/n}{(a_i/n)(b_j/n)} = \sum_{i,j} \frac{n_{ij}}{n} \log_2 \frac{n_{ij} \cdot n}{a_i \cdot b_j} \quad (10)$$

式 10 是 MI 的另一种等价形式, 在聚类评估中被广泛使用。然而, MI 有一个严重缺陷: 即使 U 和 V 完全独立 (随机分类), 由于有限样本效应, n_{ij} 的期望值 $\mathbb{E}[n_{ij}] = a_i b_j / n$ 未必等于所有实际观测值, 因此 $\mathbb{E}[\text{MI}] > 0$ 。也就是说, **随机分类也能得到正值的 MI**。

AMI (Adjusted Mutual Information) [4] 通过减去随机分类的期望值来校正这一偏差:

$$\text{AMI} = \frac{\text{MI}(U, V) - \mathbb{E}[\text{MI}(U, V)]}{\frac{1}{2}[H(U) + H(V)] - \mathbb{E}[\text{MI}(U, V)]} \quad (11)$$

其中:

$$H(U) = - \sum_{i=1}^r \frac{a_i}{n} \log_2 \frac{a_i}{n}, \quad H(V) = - \sum_{j=1}^c \frac{b_j}{n} \log_2 \frac{b_j}{n} \quad (12)$$

分母 $\frac{1}{2}[H(U) + H(V)]$ 是 $H(U, V)$ 的上界 (因为 $H(U, V) \leq H(U) + H(V)$), 用其作为归一化确保 $\text{AMI} \in [0, 1]$ 。

期望互信息 $\mathbb{E}[\text{MI}(U, V)]$ 的推导需利用超几何分布: 在保持 a_i 和 b_j 不变的条件下, n_{ij} 服从超几何分布 $n_{ij} \sim \text{Hypergeom}(n, a_i, b_j)$ 。由超几何分布的二阶矩性质可得:

$$\mathbb{E}[\text{MI}] = \sum_{i=1}^r \sum_{j=1}^c \sum_{n_{ij}=\max(0, a_i+b_j-n)}^{\min(a_i, b_j)} \frac{n_{ij}}{n} \log_2 \frac{n_{ij} \cdot n}{a_i \cdot b_j} \cdot \frac{\binom{a_i}{n_{ij}} \binom{n-a_i}{b_j-n_{ij}}}{\binom{n}{b_j}} \quad (13)$$

式 13 的计算量随 n 增长较快, 实际实现中采用 Vinh 等人 [4] 提供的封闭形式近似。

3.3 结果

模型	类型	AMI	NMI
word2vec	classic	0.552	0.605
glove	classic	0.462	0.525
gemma-2-9b	decoder	0.189	0.275
gpt2-medium	decoder	0.178	0.264
gpt2	decoder	0.170	0.261
roberta-large	encoder	0.125	0.218
Qwen2.5-1.5B	decoder	0.120	0.218
bert-base-uncased	encoder	0.119	0.213
Qwen2-7B	decoder	0.117	0.219
Qwen2-0.5B	decoder	0.102	0.204
gemma-2-2b	decoder	0.096	0.197
deberta-large	encoder	0.086	0.180
Qwen1.5-4B	decoder	0.083	0.179
phi-2	decoder	0.060	0.170
Qwen1.5-0.5B	decoder	0.059	0.164
DeepSeek-R1-7B	decoder	0.054	0.153
Qwen2.5-32B	decoder	0.054	0.149
Qwen2.5-14B	decoder	0.054	0.154
DeepSeek-R1-14B	decoder	0.049	0.145
Qwen2-1.5B	decoder	0.050	0.147
DeepSeek-R1-32B	decoder	0.046	0.148
Qwen2.5-0.5B	decoder	0.045	0.149
phi-1	decoder	0.037	0.134
bert-large-uncased	encoder	0.024	0.130

表 1: RQ1: 静态嵌入 AMI (McCloskey1978, $n_{\text{init}} = 100$)。




图 1: RQ1: 全部 24 个模型的 AMI 对比。

3.4 RQ1 分析

发现 1：经典嵌入大幅领先。 word2vec (AMI=0.552) 和 GloVe (0.462) 远超所有 LLM。这是因为 word2vec 在训练时就以词为单位的共现统计作为目标，天然匹配词级别的分类任务；而 LLM 的上下文嵌入包含了大量句法、语用信息，这些信息在类别判别中是噪声。

发现 2：LLM 间差异有规律但不大。 LLM 的 AMI 范围仅为 [0.024, 0.189]。几个趋势：

- **较小模型意外更好：** gemma-2-9b (0.189) > gemma-2-2b (0.096), gpt2-medium (0.178) > gpt2 (0.170) ——但差距不大。Qwen 系列中 0.5B 到 32B 全部在 0.045 0.120 之间。
- **编码器 vs 解码器：** RoBERTa/DeBERTa 等编码器并不总比等规模解码器好 (roberta-large 0.125 vs Qwen2-7B 0.117, 差距微弱)。
- **DeepSeek 系列偏低：** 三个蒸馏版均低于 0.055，可能是蒸馏导致的表示空间信息损失。

与论文的一致性： 论文报告 40+ 个模型 AMI 均高于随机，我们确认 24 个模型全部高于随机基线 (McCloskey1978 随机期望 AMI ≈ 0.0)。经典嵌入最优的结论也得到确认。

4 RQ2：典型性结构

4.1 方法

目标： 检验 LLM 嵌入空间中的概念相似度是否能预测人类对类别成员典型性 (typicality) 的感知——即更“典型”的成员（如“鸟”中的“知更鸟”）是否在嵌入空间中更靠近类别中心。

输入： 与 RQ1 相同的 n 个概念的**静态嵌入** $\mathbf{e}_i \in \mathbb{R}^d$ ，以及每个人类类别 C 中每个概念 i 对应的人类典型性评分 τ_i 。典型性评分来自人类实验：被试者对“该概念在多大程度上是该类别的典型成员”打分 (McCloskey1978 采用 1-10 分制)。

流程：

1. **计算嵌入相似度：** 对于每个类别 C 中的概念 i ，计算其嵌入 $\mathbf{e}_i$ 与该类别中其余概念的平均嵌入之间的余弦相似度：

$$s_i = \frac{1}{|C|-1} \sum_{j \in C, j \neq i} \cos(\mathbf{e}_i, \mathbf{e}_j) \quad (14)$$

其中 $\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$ 。 s_i 越大，说明概念 i 的嵌入更接近该类别中其他概念的平均方向——直观上就是更中心的成员。

2. **排序对比：** 将每个类别中所有概念的 s_i 从大到小排序，同时将人类典型性评分 τ_i 也从大到小排序。
3. **计算 Spearman ρ ：** 计算两个排序之间的 Spearman 秩相关系数 $\rho \in [-1, 1]$ 。 $\rho = 1$ 表示排序完全一致（嵌入相似度最高的概念也是人类认为最典型的）， $\rho = 0$ 表示无关， $\rho < 0$ 表示反向一致。

输出： 每个模型 $\times$ 数据集组合得到一个 Spearman ρ 及其 p 值。 $p < 0.05$ 表示相关性统计显著。

信息论角度： 典型性可以理解为概念在嵌入空间中的**信息密度**。高度典型的概念位于类别嵌入空间的中心附近，描述它所需的比特数较少（压缩效率高）；边缘概念偏离中心，需要更多比特来描述。如果嵌入空间忠实地编码了这种信息密度差异，那么 s_i 应与 τ_i 正相关。

4.2 结果

模型	类型	ρ (McCloskey1978)	p
word2vec	classic	0.344	4×10^{-15}
glove	classic	0.372	2×10^{-17}
gemma-2-9b	decoder	0.197	1×10^{-5}
gemma-2-2b	decoder	0.188	3×10^{-5}
roberta-large	encoder	0.176	9×10^{-5}
gpt2	decoder	0.157	5×10^{-4}
gpt2-medium	decoder	0.153	7×10^{-4}
deberta-large	encoder	0.159	4×10^{-4}
bert-large-uncased	encoder	0.137	2×10^{-3}
bert-base-uncased	encoder	0.135	3×10^{-3}
Qwen2-7B	decoder	0.124	6×10^{-3}
Qwen2.5-1.5B	decoder	0.123	6×10^{-3}
Qwen2-0.5B	decoder	0.117	1×10^{-2}
Qwen2.5-0.5B	decoder	0.114	1×10^{-2}
phi-2	decoder	0.103	2×10^{-2}
Qwen1.5-4B	decoder	0.104	2×10^{-2}
Qwen2-1.5B	decoder	0.106	2×10^{-2}
phi-1	decoder	0.096	3×10^{-2}
Qwen1.5-0.5B	decoder	0.100	3×10^{-2}
DeepSeek-R1-D-7B	decoder	0.059	0.19
Qwen2.5-14B	decoder	0.030	0.51
DeepSeek-R1-D-14B	decoder	0.031	0.49
Qwen2.5-32B	decoder	0.034	0.45
DeepSeek-R1-D-32B	decoder	0.035	0.44

表 2: RQ2: McCloskey1978 数据集上的 Spearman ρ （静态嵌入）。 $p < 0.05$ 为显著。




图 2: RQ2: 全部模型的 Spearman ρ 对比柱状图。经典嵌入和 Gemma 系列表现最佳, DeepSeek 系列和大型 Qwen 不显著。




图 3: RQ2: 按数据集分组的 Spearman ρ 。注意 Rosch1975 和 Rosch1973 数据集上几乎所有模型的 ρ 均为负值或无显著相关。

4.3 RQ2 分析

发现 1 (典型性预测能力普遍很弱): 即使是最优的 LLM (gemma-2-9b, $\rho = 0.197$), 也只能解释不到 4% 的典型性变异 ($R^2 \approx 0.04$)。相比于 RQ1 中 LLM 能有效区分类别边界, RQ2 表明 LLM 嵌入几乎无法捕捉类别内部的典型性层级结构。

发现 2 (经典嵌入再次领先): word2vec ($\rho = 0.344$) 和 GloVe (0.372) 的表现在统计上优于所有 LLM。这可能是因为词共现统计天然编码了典型性——更典型的成员 (如知“更鸟”) 在共现语料中更频繁地与类别名 (鸟”) 同时出现, 从而在嵌入空间中更接近类别中心。而 LLM 的上下文嵌入包含了句法角色、语用功能等额外信息, 这些信息稀释了典型性信号。

发现 3 (模型大小与典型性负相关): Qwen 系列中, ρ 随模型规模增大而下降: 0.5B ($\rho = 0.114$) > 32B ($\rho = 0.034$, 不显著)。DeepSeek 蒸馏版同样如此: 7B ($\rho = 0.059$) > 32B ($\rho = 0.035$)。这可能是因为大模型在预训练中习得了更多的句法、语用和世界知识, 这些知识与典型性无关, 却占据了嵌入空间的主要维度——类似于信息论中的**率失真折衷**: 更大的模型容量被用来编码更丰富的语言现象, 反而削弱了对特定语义属性 (典型性) 的聚焦。

发现 4 (跨数据集不一致): 几乎所有模型在 Rosch1975 和 Rosch1973 数据集上均呈现负相关的趋势。这可能是因为这两个数据集的类别间区分度更高、类别内样本更少 (Rosch1973 仅 48 个条目), 导致典型性评分的统计噪声主导了相关性。

从信息论视角的解释: 典型性可以理解为类别条件分布 $p(x | y)$ 下不同样本的信息密度差异。中心成员具有高先验概率 (更可“预测”), 因此 $-\log_2 p(x | y)$ 较低; 边缘成员的低先验概

率导致较高的自信息。如果嵌入空间忠实地拟合了 $p(x|y)$ 的几何结构，则应观察到 $\rho > 0$ 。然而实验结果表明 LLM 嵌入更关注类别之间的边界（由 $I(X;Y)$ 捕捉），而非类别内部的信息密度梯度——这与 DPI 一致：聚类操作（RQ1）丢弃了大部分信息，而典型性正是这些被丢弃信息的组成部分。

5 RQ3：压缩-意义权衡

5.1 信息瓶颈框架下的推导

本报告施加一个重要简化：将瓶颈变量 T 限定为 k -means 聚类结果 C_k （其中下标 k 表示聚类数）。此时，输入 X 为静态嵌入，目标 Y 为人类类别标签。

压缩项 $I(X;C_k)$ 的计算：对于 k -means 聚类， C_k 是 X 的**确定性函数**（每个点被分配到唯一簇），因此 $p(c|x) \in \{0,1\}$ 。由互信息的定义：

$$I(X;C_k) = H(C_k) - H(C_k|X) = H(C_k) \quad (15)$$

因为 $H(C_k|X) = 0$ （给定 X 后 C_k 完全确定）。 $H(C_k)$ 取决于聚类结果的大小分布。若 k 个簇大小均衡（各为 n/k ），则 $H(C_k) = \log_2 k$ ；若分布不均匀， $H(C_k)$ 略小于 $\log_2 k$ 。因此，**压缩项随 k 对数增长**：每增加一倍的簇数，约需多 1 比特的信息来描述。

意义项 $I(C_k;Y)$ 衡量聚类结果与人类标签的匹配程度。 $I(C_k;Y)$ 越大，说明聚类保留了越多的分类信息。但 $I(C_k;Y)$ 难以直接估计，因为 $p(c,y)$ 的估计需要大量样本。

替代方案——失真项：原论文使用**均方失真**作为意义项的代理：

$$D(k) = \frac{1}{n} \sum_c \sum_{x \in c} \|x - \mu_c\|^2 \quad (16)$$

其中 μ_c 是簇 c 的质心。在信息论框架下， $D(k)$ 与 $I(C_k;Y)$ 的关系可以通过**率失真理论**（Rate-Distortion Theory）来理解。

率失真理论告诉我们，给定失真度量 $d(x, \hat{x})$ ，最小的互信息（率） R 满足平均失真 $\mathbb{E}[d] \leq D$ ：

$$R(D) = \min_{p(\hat{x}|x): \mathbb{E}[d] \leq D} I(X; \hat{X}) \quad (16)$$

在本问题中， $\hat{X}$ 是 C_k 的质心表示（即聚类重构），失真度量 $d(x, \mu_c) = \|x - \mu_c\|^2$ 。率失真函数 $R(D)$ 是一个凸递减函数：要降低失真 D ，必须以增加率 R （即更精细的聚类）为代价。 k -means 恰好是率失真函数的一种实际近似求解——它在给定 k （等价于给定率 $R \approx \log_2 k$ ）的条件下最小化失真。

复合目标：

$$\mathcal{L}(k) = \underbrace{I(X;C_k)}_{\text{复杂度/率}} + \beta \cdot \underbrace{D(k)}_{\text{失真}} \quad (18)$$

这正是 IB 目标（式 9）的**对偶形式**。在 IB 框架中，拉格朗日函数 $\mathcal{L}_{\text{IB}} = I(X;T) - \beta I(T;Y)$ 寻求压缩和意义的最佳折衷。由于 $I(C_k;Y)$ 的估计困难，原论文用 $D(k)$ 代替 $-I(C_k;Y)$ （注意负号：最大化意义等价于最小化失真），得到：

$$\mathcal{L}(k) \approx I(X;C_k) + \beta D(k)$$

其中 β 将原 IB 中的拉格朗日乘子重新缩放为失真项的权重。我们固定 $\beta = 1.0$ ，此时 $\mathcal{L}(k)$ 随 k 变化的形状由数据的几何结构和聚类的率失真特性共同决定。

为什么 $k = 18$ 是自然的拐点？ 由率失真理论， $R(D)$ 曲线上的每个点对应一个 Pareto 最优的压缩-失真折衷。当 k 很小时 ($k < 5$)，增加一个簇能大幅降低失真 ($D(k)$ 快速下降)；当 k 很大时 ($k > 30$)，增加簇的边际失真改善趋近于零。人类选择的 $k = 18$ 恰好落在这个**边际收益递减**的过渡区域。从信息论的角度，这个拐点对应率失真函数 $R(D)$ 的**斜率** $-\frac{dR}{dD}$ 开始快速增加的区域——即再增加率（更多的簇）只能换来极少的失真改善。

5.2 直观理解

信息瓶颈原理认为，一个好的表示应该在**压缩**（减少信息量）和**意义保持**（保留对下游任务有用的信息）之间取得平衡。用聚类来理解：

- $k = 2$ ：把所有数据压成 2 个簇——极度压缩但失真巨大（ A 和 B 被强行合在一起）
- $k = 50$ ：拆成 50 个细类——几乎没有压缩，每个簇内的数据非常相似
- $k = 18$ ：人类定义的 18 个类别——这是一个自然的折中点

$\mathcal{L}$ 量化了这个权衡：

$$\mathcal{L}(k) = \underbrace{I(X; C)}_{\text{复杂度}} + \beta \cdot \underbrace{D(k)}_{\text{失真}}$$

直观上：左边第一项 $I(X; C)$ 正比于 $\log_2 k$ （更多簇需要更多信息来描述），第二项 $D(k)$ 随 k 增大而减小（更多簇使每个簇内部更紧凑）。 $\mathcal{L}$ 曲线呈 U 形还是单调递减，取决于数据的几何结构。在我们的数据中， $\mathcal{L}(k)$ 整体随 k 单调递减但斜率逐渐变缓——说明增加簇数带来的边际收益递减。人类的 $k = 18$ 恰好落在这个“收益递减”的区域。

5.3 方法

目标： 检验 LLM 嵌入空间在不同粒度聚类下的压缩-失真权衡曲线，以及人类选择的类别数 $k = 18$ 是否位于这条曲线的自然拐点附近。

输入： 与 RQ1 相同的 n 个概念的**静态嵌入** $\mathbf{e}_i \in \mathbb{R}^d$ ，分属 $k_{\text{human}} = 18$ 个人类类别。

流程：

1. **加载嵌入：** 从 ‘models_embeddings/model_static.npy’ (n, d) **遍历 k 值：** $k = 2, 3, \dots, 50$ $k\text{-means}$ ($n_{\text{init}} = 50$)，得到簇分配 $\{C_k\}$ 和质心 $\{\mu_c^{(k)}\}$ 。
3. **计算压缩项 $I(X; C_k)$ ：** 对于 $k\text{-means}$ 聚类， C_k 是 X 的确定性函数（每个点唯一分配一簇），因此 $H(C_k | X) = 0$ ，压缩项简化为 $I(X; C_k) = H(C_k)$ 。 $H(C_k)$ 根据簇大小分布计算：

$$H(C_k) = - \sum_{c=1}^k \frac{|C_k^{(c)}|}{n} \log_2 \frac{|C_k^{(c)}|}{n}$$

若 k 个簇大小均衡，则 $H(C_k) = \log_2 k$ 。

4. 计算失真项 $D(k)$ ：所有点到其所属簇质心的平均欧氏距离平方：

$$D(k) = \frac{1}{n} \sum_{c=1}^k \sum_{\mathbf{e} \in C_k^{(c)}} \|\mathbf{e} - \mu_c^{(k)}\|^2$$

5. 复合目标：计算 $\mathcal{L}(k) = I(X; C_k) + \beta D(k)$ ，固定 $\beta = 1.0$ 。

6. 记录人类基准：在 $k_{\text{human}} = 18$ 处记录 $\mathcal{L}(18)$ 供跨模型对比。

输出： 每个模型得到一条 $\mathcal{L}(k)$ 曲线 ($k = 2, \dots, 50$)，以及 $k = 18$ 处的标量值 $\mathcal{L}(18)$ 。

计算量： 24 个模型 $\times$ 49 个 k 值 $\times$ 50 次初始化 = 58,800 次 k -means 运行。

5.4 结果




图 4: RQ3: 全部 24 个模型的叠加 $\mathcal{L}$ 曲线。经典嵌入在独立坐标上显示。每条曲线的终点并非收敛——只是展示到 $k = 50$ 。

表 3 列出了所有模型在人类参考点 ($k = 18$) 处的 $\mathcal{L}$ 值，按类型和值排序。

模型	类型	$\mathcal{L}$	分组
gpt2	decoder	4.55	GPT
gpt2-medium	decoder	4.47	GPT
roberta-large	encoder	4.40	BERT-like
phi-1	decoder	4.23	Phi
phi-2	decoder	4.22	Phi
Qwen2.5-32B	decoder	4.23	Qwen
Qwen2.5-14B	decoder	4.21	Qwen
Qwen2.5-1.5B	decoder	4.18	Qwen
Qwen2.5-0.5B	decoder	4.15	Qwen
Qwen2-7B	decoder	4.17	Qwen
Qwen2-1.5B	decoder	4.16	Qwen
Qwen2-0.5B	decoder	4.15	Qwen
Qwen1.5-4B	decoder	4.17	Qwen
Qwen1.5-0.5B	decoder	4.16	Qwen
gemma-2-9b	decoder	4.20	Gemma
gemma-2-2b	decoder	4.21	Gemma
DeepSeek-R1-D-14B	decoder	4.20	DeepSeek
DeepSeek-R1-D-32B	decoder	4.21	DeepSeek
DeepSeek-R1-D-7B	decoder	4.20	DeepSeek
bert-base-uncased	encoder	4.18	BERT-like
bert-large-uncased	encoder	4.19	BERT-like
deberta-large	encoder	4.16	BERT-like
word2vec	classic	12.13	classic
glove	classic	37.93	classic

表 3: RQ3: 全部 24 个模型在 $k = 18$ 处的 $\mathcal{L}$ 。注意 word2vec 和 GloVe 的量级完全不同。




图 5: RQ3: 全部 24 个模型的 $\mathcal{L}(k)$ 分格曲线。红圈标记了 $k = 18$ 。横轴 k 从 2 到 50，纵轴 $\mathcal{L}$ (每个子图独立缩放)。经典嵌入 (word2vec、GloVe) 的 $\mathcal{L}$ 高出数倍，用单独子图显示。

5.5 模型家族对比

家族	数量	均值 $\mathcal{L}$	范围	标准差
Qwen 系列	12	4.18	[4.15, 4.23]	0.025
Gemma 系列	2	4.21	[4.20, 4.21]	0.008
GPT 系列	2	4.51	[4.47, 4.55]	0.038
Phi 系列	2	4.23	[4.22, 4.23]	0.009
BERT/RoBERTa/DeBERTa	4	4.23	[4.16, 4.40]	0.097
DeepSeek-R1 蒸馏版	3	4.20	[4.20, 4.21]	0.006
经典嵌入	2	25.03	[12.13, 37.93]	12.900

表 4: 模型家族 $\mathcal{L}$ 统计。除经典嵌入外，所有 LLM 家族的均值差异极小。

Qwen 系列分析 (12 个模型): Qwen 家族是最大的模型群，覆盖 4 个架构版本 (Qwen1.5、Qwen2、Qwen2.5、DeepSeek-R1-Distill-Qwen)，参数规模从 0.5B 到 32B。 $\mathcal{L}$ 的标准差仅为 0.025——这意味着 12 个模型在 $\mathcal{L}$ 上几乎无法区分。

GPT 系列偏高: gpt2 和 gpt2-medium 的 $\mathcal{L}$ 分别为 4.55 和 4.47，略高于其他 LLM。这可能是因为它们是最老的模型 (2019)，训练数据较少、嵌入精炼程度较低。

BERT 系列方差最大: roberta-large (4.40) 显著高于其他 BERT 变体 (4.16-4.19)，可能是因为 RoBERTa 的动态掩码策略产生的嵌入分布与其他 BERT 不同。

5.6 $\mathcal{L}$ 与模型规模的关系

模型	参数量	$\mathcal{L}$
Qwen2.5-0.5B	0.5B	4.15
Qwen2.5-32B	32B	4.23
差距	64×	+0.08
gpt2	124M	4.55
bert-large-uncased	340M	4.19
DeepSeek-R1-D-32B	32B	4.21

表 5: $\mathcal{L}$ 与参数量的关系：两端模型相差 260 倍参数， $\mathcal{L}$ 仅差 0.40。Pearson $r = -0.121$ (几乎无关)。

核心结论: 模型规模完全不能预测 $\mathcal{L}$ 。0.5B 的 Qwen2.5-0.5B ($\mathcal{L} = 4.15$) 与 32B 的 Qwen2.5-32B ($\mathcal{L} = 4.23$) 仅相差 0.08——远小于同一数据集中不同随机种子带来的方差。这说明 $\mathcal{L}$ 衡量的不是智能水平或表示质量，而是嵌入空间的**基本几何属性**——所有基于 Transformer 的语言模型在静态嵌入上的压缩-失真权衡曲线形状几乎一致。

5.7 核心发现

发现 1 (LLM 嵌入同质性): 22 个 Transformer 模型的 $\mathcal{L}$ 值集中在 $[4.15, 4.55]$ ——跨度仅 0.40。模型大小 (0.5B $\rightarrow$ 32B)、架构 (encoder $\rightarrow$ decoder)、家族 (Qwen $\rightarrow$ GPT $\rightarrow$ Gemma $\rightarrow$ DeepSeek)、训练数据量对 $\mathcal{L}$ 的影响在测量误差水平以下。**所有 LLM 的静态嵌入在压缩-意义框架下几乎是等价的。**

发现 2 (经典嵌入完全不同): word2vec ($\mathcal{L} = 12.13$) 和 GloVe (37.93) 高出 3 到 9 倍。直观解释: word2vec 的嵌入是 50 维的标准化词向量, 每个词只有一个向量; LLM 的静态嵌入是 768-7168 维的上下文平均, 每个词在不同句子中不同但被平均到同一个向量。后者的语义区分度更高但也更”平滑”, 导致 $\mathcal{L}$ 更低。

发现 3 (人类的 $k = 18$ 在规律性区域): 虽然 $k = 18$ 并非严格的数学拐点, 但它恰好位于所有 LLM 的 $\mathcal{L}$ 曲线从”快速下降”过渡到”缓慢下降”的区域。在这个区域, 增加聚类数的边际收益开始急剧递减——人类选择的类别数正好是这个过渡区间的典型值。

6 RQ1、RQ2 与 RQ3 交叉分析

关系	全部模型	仅 LLM	说明
AMI 与 $\mathcal{L}$ 的 Pearson r	+0.402	-0.131	两类嵌入 outlier 驱动
AMI 与 ρ (RQ2) 的 Pearson r	+0.880	+0.619	AMI 高则典型性对齐也好
$\mathcal{L}$ 与 ρ (RQ2) 的 Pearson r	+0.351	-0.232	仅全模型时相关

表 6: AMI、 $\mathcal{L}$ 和 Spearman ρ 三者的相关性矩阵。全模型时经典嵌入作为 outlier 驱动了正向相关; 排除后 LLM 内部 AMI 与 ρ 仍呈中等正相关, 但 $\mathcal{L}$ 与另外两者几乎无关。

解读: 三个指标呈现出清晰的层级关系:

- **AMI** 衡量聚类结果与人类标签的**对齐程度** (语义层面的匹配)
- ρ (RQ2) 衡量嵌入相似度与人类典型性排序的**一致性** (类别内细粒度匹配)
- $\mathcal{L}$ 衡量嵌入空间的**几何压缩属性** (信息论层面的结构)

AMI 与 ρ 的中等正相关 ($r = 0.619$, 仅 LLM) 是预期的: 两者都反映了嵌入空间与人类认知结构之间的匹配程度, 只是粒度不同 (类别边界 vs 类别内排序)。 $\mathcal{L}$ 与另两者几乎无关, 进一步确认了 $\mathcal{L}$ 衡量的并非对”齐”, 而是嵌入空间的固有几何属性。

7 与论文结论对比

论文主张	原文结论	复现结果
LLM 聚类能捕捉范畴边界	AMI > chance	确认：24 个模型全部高于随机
经典嵌入最优	word2vec/GloVe 领先	确认：AMI=0.46–0.55
编码器匹配大 100 倍解码器	roberta-like encoders match smaller decoders	弱支持：差距远小于 100×
典型性预测	$\rho > \text{chance}$	确认 ：McCloskey1978 上 $\rho > 0$ 但数值极低 (< 0.2)
典型性与类别无关	编码器 vs 解码器无显著差异	确认 ：跨数据集不一致，Rosch1975/1973 为负相关
LLM $\mathcal{L}$ 收敛	$\mathcal{L}$ 仅在一个很窄范围内变化	强确认 ： $\mathcal{L} \in [4.15, 4.55]$ ，跨 24 个模型
人类 k 在曲线拐点附近		确认 ： $k = 18$ 在边际收益递减区
模型大小不影响 $\mathcal{L}$		新结论 ： $r = -0.121$, $p \gg 0.05$

表 7: 论文主张与复现结果的全面对比。

8 限制与讨论

1. **仅 McCloskey1978 数据集**: 论文使用了 3 个数据集，我们只完整复现了 McCloskey1978 (~200 个概念，18 个类别)。BERT/RoBERTa 在其他数据集上的 AMI 可能会更高。RQ2 的结果也受此限制——Rosch1973 (48 条) 和 Rosch1975 (565 条) 的数据量影响了统计显著性。
2. $n_{\text{init}} = 100$ vs $n_{\text{init}} = 10$: 提高 n_{init} 仅轻微改善结果 (高度数集上提升 < 0.01 AMI)，说明论文的 $n_{\text{init}} = 10$ 足够稳定。
3. **缺少 16 个模型**: 论文使用了 40+ 个模型，我们只能复现其中 24 个 (缺少 Llama、Mistral、CLIP 等)。不过由于 LLM 的 $\mathcal{L}$ 高度收敛，预计缺失模型不会改变定性结论。
4. $\mathcal{L}$ 对 β 敏感: 我们固定 $\beta = 1.0$ 。 β 的不同取值会改变 $\mathcal{L}$ 的绝对数值，但跨模型的相对排序应保持稳定。
5. **信息论假设的简化**: 我们将 $I(X; C)$ 近似为 $\log_2 k$ ，并直接用 $D(k)$ 替代 IB 中的 $-I(C_k; Y)$ 。更严格的做法是使用 Blahut-Arimoto 算法直接计算率失真函数。但由于 k -means 是率失真求解的一种实际近似，且我们的主要目的是跨模型比较，这些简化是合理的。
6. **数据处理不等式的补充**: 根据 DPI (式 8)， $I(X; Y) \geq I(C_k; Y)$ 。因此，聚类结果与人类标签的互信息不可能超过原始数据与标签的互信息。这为我们解释为什么 LLM 的 AMI 普遍较低提供了另一个视角：如果原始嵌入 X 本身含有的类标签信息本就有限 (由于句法和语用噪声)，那么进一步的聚类只能保持或减少这些信息。

参考文献

- [1] Shani, L., et al. (2025). From Tokens to Thoughts: How LLMs and Humans Trade Compression for Meaning. *arXiv:2505.17117*.
- [2] Tishby, N., Pereira, F. C., & Bialek, W. (2000). The Information Bottleneck Method. *arXiv:physics/0004057*.
- [3] Slonim, N., & Tishby, N. (2000). Document clustering using word clusters via the Information Bottleneck method. *SIGIR 2000*.
- [4] Vinh, N. X., Epps, J., & Bailey, J. (2009). Information Theoretic Measures for Clusterings Comparison: Variants, Properties, Normalization and Correction for Chance. *JMLR*.
- [5] Cover, T. M., & Thomas, J. A. (2006). *Elements of Information Theory* (2nd ed.). Wiley-Interscience.