

From Tokens to Thoughts 复现报告

RQ1 ($n_{\text{init}}=100$) 与 RQ3——范畴对齐与压缩-意义权衡

复现团队

概述

我们使用 24 个模型 (McCloskey1978 数据集静态嵌入) 复现了论文《From Tokens to Thoughts: How LLMs and Humans Trade Compression for Meaning》[1]。本报告涵盖 RQ1 (基于 AMI 的范畴对齐, $n_{\text{init}} = 100$) 和 RQ3 (基于 $\mathcal{L}$ 曲线的压缩-意义权衡)。

1 RQ1: 范畴对齐

1.1 方法

对每个模型 $\times$ 数据集组合, 在静态嵌入上运行 k -means 聚类 ($n_{\text{init}} = 100$, $k =$ 人类类别数)。评估指标为聚类结果与人类标签之间的调整互信息 (AMI)。参照论文做法, 每次聚类重复 100 次不同随机种子并取最优结果。

1.2 结果（静态嵌入，McCloskey1978）

模型	类型	AMI	NMI
word2vec	classic	0.552	0.605
glove	classic	0.462	0.525
gemma-2-9b	decoder	0.189	0.275
gpt2-medium	decoder	0.178	0.264
gpt2	decoder	0.170	0.261
roberta-large	encoder	0.125	0.218
Qwen2.5-1.5B	decoder	0.120	0.218
bert-base-uncased	encoder	0.119	0.213
Qwen2-7B	decoder	0.117	0.219
Qwen2-0.5B	decoder	0.102	0.204
gemma-2-2b	decoder	0.096	0.197
deberta-large	encoder	0.086	0.180
Qwen1.5-4B	decoder	0.083	0.179
phi-2	decoder	0.060	0.170
Qwen1.5-0.5B	decoder	0.059	0.164
DeepSeek-R1-7B	decoder	0.054	0.153
Qwen2.5-32B	decoder	0.054	0.149
Qwen2.5-14B	decoder	0.054	0.154
DeepSeek-R1-14B	decoder	0.049	0.145
Qwen2-1.5B	decoder	0.050	0.147
DeepSeek-R1-32B	decoder	0.046	0.148
Qwen2.5-0.5B	decoder	0.045	0.149
phi-1	decoder	0.037	0.134
bert-large-uncased	encoder	0.024	0.130

表 1: RQ1: 静态嵌入 AMI (McCloskey1978, $n_{\text{init}} = 100$)。经典嵌入大幅领先，大部分 LLM 的 AMI 低于 0.15。

核心发现：经典嵌入（word2vec、GloVe）以显著优势领先所有 LLM。在 LLM 中，较小模型（gemma-2-9b、gpt2）的范畴对齐效果优于大模型。编码器模型并不比同等规模的解码器模型表现更好。




图 1: RQ1: 全部 24 个模型的 AMI ($n_{\text{init}}=100$), 跨数据集均值。

2 RQ3: 压缩-意义权衡

2.1 方法

对每个模型, 在 McCloskey1978 静态嵌入上计算 $\mathcal{L}(k) = I(X; C) + \beta \cdot \text{Distortion}(k)$, 遍历 $k = 2$ 到 50 (KMeans, $n_{\text{init}} = 50$)。然后以 $k_{\text{human}} = 18$ (真实类别数) 作为人类基准点进行评估。

$\mathcal{L}$ 曲线刻画了信息瓶颈 (Information Bottleneck) 中的权衡关系: k 过小时失真大 (欠拟合), k 过大时复杂度高 (过拟合)。人类定义类别恰好落在曲线的自然拐点附近。

2.2 结果




图 2: RQ3: 全部 24 个模型的叠加 $\mathcal{L}$ 曲线。 $k = 18$ 附近的散点标记了人类基准 $\mathcal{L}$ 。

表 2 列出了所有模型在人类参考点 ($k = 18$) 处的 $\mathcal{L}$ 值。

模型	类型	$\mathcal{L} (k = 18)$
gpt2	decoder	4.55
gpt2-medium	decoder	4.47
roberta-large	encoder	4.40
phi-1	decoder	4.23
phi-2	decoder	4.22
Qwen2.5-32B	decoder	4.23
Qwen2.5-14B	decoder	4.21
Qwen2.5-1.5B	decoder	4.18
Qwen2.5-0.5B	decoder	4.15
Qwen2-7B	decoder	4.17
Qwen2-1.5B	decoder	4.16
Qwen2-0.5B	decoder	4.15
Qwen1.5-4B	decoder	4.17
Qwen1.5-0.5B	decoder	4.16
gemma-2-9b	decoder	4.20
gemma-2-2b	decoder	4.21
DeepSeek-R1-Distill-Qwen-14B	decoder	4.20
DeepSeek-R1-Distill-Qwen-32B	decoder	4.21
DeepSeek-R1-Distill-Qwen-7B	decoder	4.20
bert-base-uncased	encoder	4.18
bert-large-uncased	encoder	4.19
deberta-large	encoder	4.16
word2vec	classic	12.13
glove	classic	37.93

表 2: RQ3: 全部 24 个模型在人类 $k = 18$ 处的 $\mathcal{L}$ (McCloskey1978, 静态嵌入)。

2.3 核心发现

1. LLM 嵌入在 $\mathcal{L}$ 下几乎一致。全部 22 个 Transformer 模型的 $\mathcal{L}$ 值集中在极窄的区间 $[4.15, 4.55]$ 内——跨度仅 0.40。模型规模 (0.5B 到 32B 参数)、架构 (编码器 vs 解码器) 和训练数据对该指标的影响微乎其微。

2. 经典嵌入偏差极大。 word2vec ($\mathcal{L} = 12.13$) 和 GloVe ($\mathcal{L} = 37.93$) 高出 3 到 9 倍, 反映了两类嵌入在表示几何上的本质差异: 经典嵌入是稠密的低维词级向量, 而 LLM 嵌入是高维上下文表示。

3. 人类类别位于曲线拐点。对于每个模型, $k = 18$ 都落在或非常接近 $\mathcal{L}(k)$ 曲线的拐点区域——即增加更多聚类数后失真降低的边际收益开始递减的位置。这表明人类的概念本体与嵌入空间中一个自然的最优复杂度点对齐, 且这个最优值在 LLM 间是普遍一致的。

3 与论文对比

论文主张	论文结论	我们的结果
LLM 能捕捉范畴边界 编码器匹敌百倍大解码器	全部 40+ 个模型 AMI 高于随机 编码器匹配大 100 倍的解码器	确认：24 个模型均高于随机 弱支持：roberta-large(0.125) $\approx$ Qwen2-7B(0.117)
经典嵌入最优	word2vec/GloVe 领先	确认：经典嵌入 AMI=0.46 0.55
LLM 的 $\mathcal{L}$ 跨规模收敛	所有 LLM 的 $\mathcal{L}$ 范围狭窄	确认：22 个 Transformer 模型 $\mathcal{L} \in [4.15, 4.55]$
人类 k 在曲线拐点	人类类别与 $\mathcal{L}$ 拐点对齐	确认： $k = 18$ 在每个模型的拐 点附近

表 3: 论文主张与复现结果的对比。

4 可视化




图 3: RQ3: 全部 24 个模型的 $\mathcal{L}(k)$ 分格曲线。红圈标记了人类参考点 $k = 18$ 。经典嵌入 (word2vec、GloVe) 的 $\mathcal{L}$ 远高于其他模型, 显示在独立坐标上。

参考文献

- [1] Shani et al. (2025). From Tokens to Thoughts. *arXiv:2505.17117*.